QMANUS_mx

Plataforma SaaS Multi-Tenant para Enjambres de IA Empresarial

"La base de datos no es solo almacenamiento. Es la mente del agente."

Hackathon Build | TiDB · Alibaba Cloud · Qwen AI

El Problema de Escalamiento

$$X \times Y \times Z$$

X Inquilinos ejecutando **Y** Agentes, explorando **Z** ramas paralelas.

Las bases de datos tradicionales colapsan bajo la amplificación masiva de escritura. QMANUS_mx resuelve esto usando la arquitectura HTAP de TiDB sin degradar el rendimiento de ningún inquilino.

Arquitectura de 3 Capas

1. Orquestación (Qwen)

Meta-Agentes impulsados por Qwen que analizan registros de tareas, detectan patrones de falla y optimizan secuencias de herramientas por inquilino en tiempo real.

2. Alibaba Cloud Infra

Enrutamiento seguro a través de API Gateway y ACK, usando PAI-EAS para el modelo Qwen, validación estricta de JWT y aislamiento lógico vía RAM.

3. TiDB (Memoria Larga)

Nodos TiKV manejan el OLTP (estado en vivo de agentes), mientras las réplicas TiFlash procesan la analítica OLAP sin competir por recursos de cómputo.

Pilares Técnicos: Aislamiento y Estado

Aislamiento de Inquilinos

- **Particionamiento HASH:** Datos físicamente distribuidos por `tenant_id`.
- **Seguridad de Nivel de Fila:** Middleware inyecta el ID del inquilino desde el JWT a un ContextVar en FastAPI.
- **Aislamiento Comprobado:** El Inquilino A jamás podrá consultar las sesiones del Inquilino B.

TiDB como Memoria

- **No solo registros:** La base de datos guarda planes de tareas, resultados intermedios y llamados a herramientas.
- **Máquina de Estado:** Flujo controlado desde PLANNING hasta SYNTHESIZING.
- **Flexibilidad:** Persistencia estructurada usando columnas JSON nativas en TiDB.

Pilares Técnicos: Escala e IA

Concurrencia (HTAP)

¿50 agentes escribiendo simultáneamente?

- **Escrituras:** Van directo a TiKV (OLTP) con control de concurrencia optimista.
- **Analítica:** Consultas pesadas van a réplicas TiFlash (OLAP).
- **Cero Bloqueos:** La meta-IA lee datos masivos sin afectar a los agentes activos.

Orquestación Meta-IA

Mejora continua y automática.

- El Meta-Agente lee las últimas 24h de sesiones vía TiFlash.
- Qwen-Max devuelve un JSON con optimizaciones exactas de herramientas.
- Escribimos las recomendaciones de vuelta en TiDB para mejorar la eficiencia.

¿Por qué TiDB?

Desafío Arquitectónico	Arquitectura Tradicional	La Solución QMANUS_mx
Persistencia de Estado	Redis (volátil) + Postgres (separado)	**Clúster único HTAP** (todo en uno)
Analítica en Vivo	Requiere pipeline ETL (horas de retraso)	**Réplica TiFlash** (datos instantáneos)
50 Agentes Concurrentes	Bloqueos de tablas, rendimiento degradado	**Concurrencia optimista**, recursos aislados
Aislamiento Multi-Tenant	Solo a nivel de aplicación (propenso a errores)	**Particiones DB + Middleware**

Impacto en la Demo en Vivo

12ms

Consulta Analítica en TiFlash

vs 890ms en TiKV (OLTP)

Aislamiento Comprobado (404)

Si el Inquilino B intenta consultar una sesión del Inquilino A, nuestro middleware lo intercepta y la base de datos retorna 0 filas de forma segura.

Meta-Agente en Acción

Las fallas de los agentes son procesadas por Qwen, convirtiendo un historial de ejecución crudo en optimizaciones accionables en tiempo real.

Ready to Scale.

Despliega tu enjambre de agentes empresariales hoy.

ALIBABA CLOUD × TiDB × QWEN